

Vector Autoregression (VAR)

Prognosen dynamischer Systeme mit mehreren
Zeitreihen


Kernidee

VAR denkt in Systemen:
Jede Größe wird durch ihre eigenen Vergangenheitswerte
und die Vergangenheitswerte aller anderen Größen erklärt.

*Deshalb muss VAR immer als System bewertet werden – nicht als
einzelne Prognose.*

Business Case: Modellierung eines
makroökonomischen Systems mit VAR

Wirtschaft als dynamisches System



Warum höre ich jetzt besonders genau hin?

Nach der Theorie & Praxisphase kannst du:

- ✓ verstehen, wann VAR sinnvoll ist
- ✓ die VAR(p)-Formel lesen und interpretieren
- ✓ ein VAR-Modell konzeptionell aufbauen
- ✓ Ergebnisse richtig einordnen
- ✓ Grenzen von VAR kennenlernen

Von Zeitreihen zu Prognosemodellen

Zeitreihe

Eine über die Zeit beobachtete Variable. Bspw. Inflation, Leitzins, etc.

Prognosemodell

Ein Modell, das historische Beobachtungen nutzt, um zukünftige Entwicklungen abzuleiten.

Vergangenheit

Prognosemodell

Prognose (Zukunft)

Merksatz: Prognosemodelle nutzen historische Muster, um zukünftige Werte vorherzusagen.

Warum reichen einzelne Zeitreihen oft nicht aus?


Beispiel:

Monat	Inflation
Jan	2,1 %
Feb	2,3 %
Mrz	2,5 %

**Frage: Reichen
Vergangenheitswerte der Inflation
allein aus, um die zukünftige
Inflation zu prognostizieren?**




Wirtschaft als dynamisches System




Univariate vs. Multivariate Zeitreihen

Univariat (bspw. ARIMA)



Multivariat (VAR)



Merkmale:

- ✓ Eine Variable
- ✓ Vergangenheit davon bestimmt Prognose

- ✓ Keine Berücksichtigung anderer Einflussgrößen
- ✓ Geeignet für einfache Use-Cases

Merkmale:


- ✓ Mehrere Variablen
- ✓ Jede Variable wird durch alle anderen und sich selbst erklärt

✓ Erfasst

- ✓ Wechselwirkungen- und einflüsse
- ✓ Bessere Prognose bei komplexen Systemen

VAR denkt in Systemen

Wirtschaft als dynamisches System



Wechselwirkungen => Variablen beeinflussen sich gegenseitig

Zeitliche Verzögerungen => Effekte treten oftmals nicht sofort auf, sondern wirken verzögert.


Rückkopplungen => Veränderungen heute beeinflussen zukünftige Werte

Ganzheitliches System => Nur die gemeinsame Betrachtung aller Variablen liefert konsistente und realistische Prognosen.

Warum Verzögerungen der eigentliche Hebel sind

VAR nutzt vergangene Werte (Lags), um die Zukunft des gesamten Systems zu prognostizieren.

Beispiel: Wirkung einer Zinserhöhung



Die VAR(p)-Formel wirklich lesen

$$y_t = c + A_1 y_{t-1} + A_2 y_{t-2} + \dots + A_p y_{t-p} + e_t$$

 y_t

Vektor aller Variablen zum Zeitpunkt t

 c

Intercept-Vektor: Basisniveau der Gleichungen

 A_i

Koeffizientenmatrix für Lag i

 p

Lag Order: wie viele Vergangenheitsperioden genutzt werden

 e_t

Fehlerterm: neue Information, die das Modell nicht erklärt

Was steht in A_1?

Für drei Variablen enthält A_1 als Beispiel neun Koeffizienten:

	unemploym_rate_t-1	fed_funds_rate_t-1	industrial_prod_t-1	
unemploym_rate_t	a11	a12	a13	Zeile = Zielgleichung Spalte = erklärender Lag
fed_funds_rate_t	a21	a22	a23	
industrial_prod_t	a31	a32	a33	

a_12 bedeutet: Effekt von fed_funds_rate_t-1 auf unemploym_rate_t, wenn unemploym_rate die Zielgleichung ist.

Jede Variable bekommt ihre eigene Regression

unemploy_rate_t

$$= f(\text{unemploy_rate}_{t-1}, \text{inflation_cpi}_{t-1}, \text{fed_funds_rate}_{t-1}, \text{industrial_prod}_{t-1}, \dots)$$

fed_funds_rate_t

$$= f(\text{fed_funds_rate}_{t-1}, \text{inflation_cpi}_{t-1}, \text{industrial_prod}_{t-1}, \text{unemploy_rate}_{t-1}, \dots)$$

industrial_prod_t

$$= f(\text{industrial_prod}_{t-1}, \text{inflation_cpi}_{t-1}, \text{fed_funds_rate}_{t-1}, \text{traffic}_{t-1}, \dots)$$

inflation_cpi_t

$$= f(\text{inflation_cpi}_{t-1}, \text{fed_funds_rate}_{t-1}, \text{industrial_production}_{t-1}, \dots)$$

VAR trainiert diese Gleichungen gemeinsam als System, auch wenn die Schätzung praktisch oft Gleichung für Gleichung per OLS erfolgt.

Warum VAR bei vielen Variablen schnell groß wird

$$\text{Anzahl Lag-Koeffizienten} = k^2 \cdot p$$

$$k = 3, p = 2$$

$$3^2 \cdot 2 = 18 \text{ Lag-Koeffizienten}$$

$$k = 5, p = 4$$

$$5^2 \cdot 4 = 100 \text{ Lag-Koeffizienten}$$

$$k = 10, p = 6$$

$$10^2 \cdot 6 = 600 \text{ Lag-Koeffizienten}$$

**Konsequenz: VAR ist stark für kleine Systeme, aber riskant bei vielen Variablen und kurzen Historien.
→ Overfitting-Risiko**

AIC, BIC oder RMSE wählen p

Informationskriterien balancieren Modellfit und Komplexität.

AIC

oft flexibler: wählt mehr Lags

BIC

konservativer: stärkere
Komplexitätsstrafe

RMSE

testet Lags auf einem
zurückgehaltenen Teil der
Trainingsdaten

**Warum nicht einfach p sehr groß
wählen?**

- mehr Parameter
- größeres Overfitting-Risiko
- weniger effektive Trainingsbeobachtungen
- Forecast kann instabiler werden

Für kleine bis mittlere Business-Datensätze ist BIC oft ein guter Startpunkt; AIC eignet sich als Sensitivitätscheck.

AIC, BIC oder RMSE wählen p

AIC/BIC

Nutzen die Daten auf denen
das Modell trainiert wurde

Anzahl Lag-Koeffizienten

$$Kriterium(p) = \ln \det(\sum_u (p)) + c(T) * K^2 p$$

Geschätzte Kovarianzmatrix

Strafterm

$$AIC: \frac{2}{T}$$

$$BIC: \frac{\ln T}{T}$$

Strafterme c(T):

T: Länge der Zeitreihe (Wie viele Daten)

RMSE

Benötigt Daten, welche das
Modell noch nicht kennt
(Validierungs-Daten)


$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2}$$

Fazit: RMSE benötigt Daten, welche nicht für das Training genutzt werden dürfen aber kann die Vorhersage abhängig vom Lag direkt an den ungesehenen(!) Daten messen, statt sie über den Strafterm zu schätzen.

Warum VAR nicht einfach Trends lernen sollte


Stationär

- Mittelwert ungefähr stabil
- Varianz ungefähr stabil
- Autokorrelation stabiler über Zeit




Nicht stationär

- Trend, Drift oder Strukturbruch
- Scheinkorrelation möglich
- Koeffizienten können instabil werden




Praxis: log-transformieren, differenzieren, ADF-Test nutzen und immer auch visuell prüfen.

Von Business-Level zu Modell-Input und zurück



Wichtig: Ein Forecast auf $\text{diff}(\log x)$ ist nicht direkt eine Absatzprognose. Erst die Rücktransformation macht ihn businessfähig.

Mehrschritt-Prognose sind rekursiv



VAR prognostiziert den gesamten Vektor y : Demand, Preis, Marketing und Traffic bekommen gleichzeitig Prognosen.

Je weiter der Prognose-Horizont, desto stärker können sich Fehler rekursiv fortpflanzen.

Granger, IRF und FEVD richtig einordnen

Granger Causality

Vergangenheit von X verbessert
Prognose von Y.

Keine echte Kausalität.

Impulse Response

Reaktion des Systems auf einen
Schock.

Hilfreich, aber modellabhängig.

FEVD

Anteil der Forecast-Unsicherheit
nach Schockquelle.
(Beruht auf Impuls Response)

Interpretationshilfe, kein Beweis.

Merksatz: VAR liefert prognostische und dynamische Hinweise, aber keine automatische Business-Kausalität.

Granger-Causality

Restringiert (y nur durch y-lags)


$$y_t = c + \alpha_1 y_{t-1} + \dots + \alpha_p y_{t-p} + e_t^R$$

Unrestringiert (y auch durch x-lags)

$$y_t = c + \alpha_1 y_{t-1} + \dots + \alpha_p y_{t-p} + \beta_1 x_{t-1} + \dots + \beta_p x_{t-p} + e_t^R$$

Nullhypothese:

$$H_0: \beta_1 = \beta_2 = \dots = \beta_p = 0$$



Merken: Nur weil X zur Verbesserung der Vorhersage von Y beiträgt, muss es keine Kausalität geben!

Impulse Response


$$y_t = \sum_{i=0}^{\infty} \Phi_i u_{t-i} \quad \Phi_i = A^i$$

Problem an Formel:


Die Variablen beeinflussen sich untereinander, wodurch der Impuls in einer Variable einen Impuls in den anderen erzeugt.

Lösung: Cholesky-Zerlegung

Die Cholesky-Reihenfolge als Annahme: wer darf im selben Moment auf wen wirken?



Gleichzeitige Wirkung (Reihenfolge der Variablen)



Wann VAR stark ist und wann es gefährlich wird

Stark, wenn ...

- wenige relevante Variablen
- gleiche Frequenz und saubere Historie
- dynamische Wechselwirkung plausibel
- lineare Approximation akzeptabel
- Interpretierbarkeit wichtig

Vorsicht, wenn ...

- viele Variablen oder viele Lags
- kleine Stichprobe
- Nicht-Stationarität
- Multikollinearität
- Strukturbrüche und Ausreißer

Finaler Takeaway: VAR ist ein erklärbarer Klassiker für kleine multivariate Zeitreihensysteme. Mehr Variablen sind nur dann besser, wenn sie echte, stabile Prognoseinformation liefern.

[Live Demo]

Danke! Gibt es Fragen?

Code Basis

https://github.com/GermanCodelsAwful/vector_autoregression_AI4BP

